

Advanced Industrial Mathematics

Fall 2025

Ju Ming

jming@hust.edu.cn

Huazhong University of Science and Technology

October 26, 2025

1. 插值法

1.1 Lagrange 插值

1.2 Newton插值

1.3 差分与等距节点的Newton插值

2. 函数逼近

3. 数值积分

4. ODE的数值解法

5. 线性方程组的解法

6. 非线性方程（组）的数值解法

插值问题

- ▶ **函数逼近问题:** 设函数 $y = f(x)$ 定义在区间 $[a, b]$ 上, 其具体的公式未知, 已知坐标点 $\{(x_i, y_i) : y_i = f(x_i), 0 \leq i \leq n\}$ 。先希望找到一个性质较好 (例如: 比较光滑, 形式简单) 的函数 $P(x)$, 使得

$$P(x_i) = y_i, 0 \leq i \leq n$$

作为 $y = f(x)$ 的一个近似。

从几何上看, n 次插值多项式 $P_n(x)$, 是一条 n 次代数曲线, 它通过曲线 $y = f(x)$ 上的 $n+1$ 个点 $(x_i, y_i) (i = 0, 1, \dots, n)$.

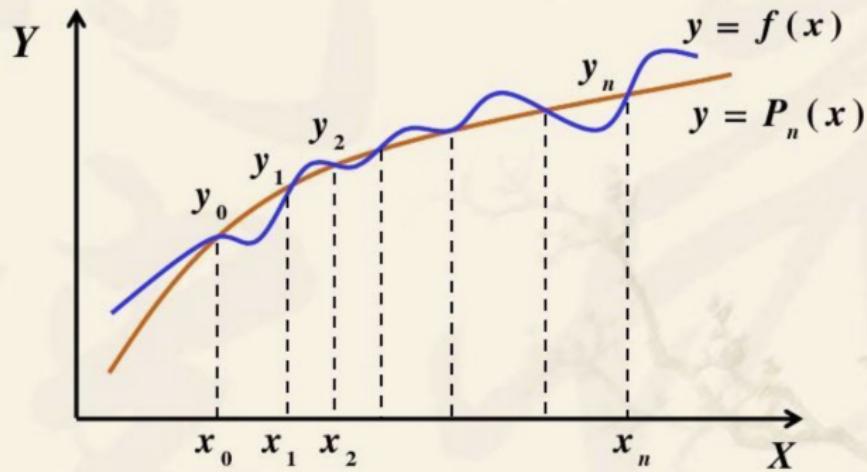


Figure: 用 $y = P_n(x)$ 来逼近 $y = f(x)$

Example 1.1.1

在上述函数逼近问题中，假设 $y = f(x)$ 的插值逼近函数 $P_n(x)$ 为 n 阶多项式，即

$$P_n(x) = \sum_{i=0}^n a_i x^i$$

试求出该插值多项式的形式。

Example 1.1.1

在上述函数逼近问题中，假设 $y = f(x)$ 的插值逼近函数 $P_n(x)$ 为 n 阶多项式，即

$$P_n(x) = \sum_{i=0}^n a_i x^i$$

试求出该插值多项式的形式。

Ans: 由已知,

$$y_k = P_n(x_k) = \sum_{i=0}^n a_i x_k^i, 0 \leq k \leq n$$

即

$$\begin{pmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 1 & x_n & x_n^2 & \cdots & x_n^n \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

上式记为 $A\alpha = Y$, 显然 $\det(A)$ 是一个 $(n+1)$ 阶范德蒙行列式。

$$\det(A) = \prod_{n \geq i > j \geq 0} (x_i - x_j)$$

若 x_0, x_1, \dots, x_n 互不相同, 则 $\det(A) \neq 0$, 此时有唯一解

$$\alpha = A^{-1}Y$$

Theorem 1.1.1

满足 $P_n(x_i) = y_i, 1 \leq i \leq n$ 的插值多项式存在且唯一。

拉格朗日 (Lagrange) 插值多项式

已知 $\{(x_i, y_i)\}_{0 \leq i \leq n}$, 这里 $y_i = f(x_i)$ 考虑 n 次多项式

$$l_i(x) = \frac{\prod_{\substack{0 \leq j \leq n, j \neq i}} (x - x_j)}{\prod_{\substack{0 \leq j \leq n, j \neq i}} (x_i - x_j)}, \text{ 这里 } x_i \neq x_j, 0 \leq i, j \leq n$$

显然

$$l_i(x_i) = 1; l_i(x_j) = 0$$

定义 $y = f(x)$ 的 **Lagrange(n次)插值多项式**:

$$L_n(x) = \sum_{i=0}^n l_i(x) y_i = \sum_{i=0}^n c_i \prod_{\substack{0 \leq j \leq n, j \neq i}} (x - x_j)$$

此时, 必有 $L_n(x_i) = y_i, 0 \leq i \leq n$, l_i 称为 **Lagrange 基函数**

Example 1.1.2

设 $y = \ln(x)$ 并给定如下函数表，求 $P_4(x)$ 。

x_i	10	11	12	13	14
y_i	2.3026	2.3979	2.4849	2.5649	2.6391

Ans:

- ▶ 方法1: $\alpha = A^{-1}Y$, 有

$$\alpha = [0.3886, 0.3371, -0.0212, 0.0008, -0.0000]$$

- ▶ 方法2: $L(x) = \sum_{i=0}^4 c_i \prod_{4 \geq j \geq 0, i \neq j} (x - x_j)$, 这里

i	0	1	2	3	4
c_i	0.0959	-0.3996	0.6212	-0.4275	0.1100

Lagrange 插值多项式的截断误差

Theorem 1.1.2

设 $f^{(n)}(x)$ 在 $[a, b]$ 上连续, $f^{(n+1)}(x)$ 在 (a, b) 内存在, 节点
 $a \leq x_0 < x_1 < \cdots < x_n \leq b$, $L_n(x)$ 是 n 阶 Lagrange 插值多项式,
 $\forall x \in [a, b]$, 截断误差 (插值余项)

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$$

这里 $\xi \in (a, b)$, $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$.

注意:

- ▶ 在上述误差估计式中, 要求 $f(x)$ $(n+1)$ 阶可导
- ▶ 若 $\max_{x \in (a, b)} |f^{(n+1)}(x)| \leq M_{n+1}$, 则

$$|R_n(x)| \leq \frac{M_{n+1}}{(n+1)!} |\omega_{n+1}(x)|$$

Example 1.1.3

已知函数 $y = e^{-x}$ 在 $x = 1, 2, 3$ 的值，试估计线性插值，二次插值计算的 $e^{2.1}$ 的截断误差

Definition 1.1.4

舍入误差 (round-off error)，是指运算得到的近似值和精确值之间的差异。

Newton 插值

Definition 1.2.1

$$f[x_i, x_j] = \frac{f(x_i) - f(x_j)}{x_i - x_j}$$

称为函数 $f(x)$ 关于点 x_i, x_j 的**一阶差商**,

$$f[x_i, x_j, x_k] = \frac{f[x_i, x_j] - f[x_j, x_k]}{x_i - x_k}$$

称为函数 $f(x)$ 关于点 x_i, x_j, x_k 的**二阶差商**, 类似地:

$$f[x_0, x_1, \dots, x_k] = \frac{f[x_0, x_1, \dots, x_{k-1}] - f[x_1, \dots, x_k]}{x_i - x_k}$$

称为函数 $f(x)$ 关于点 $x_i, 1 \leq i \leq k$ 的**k阶差商**,

注意

- ▶ k阶差商由 $k+1$ 个点构造而成
- ▶ 定义零阶差商为 $f(x_0)$

Corollary 1.2.2

- ▶ k 阶差商可以表为 $f(x_0), f(x_1), \dots, f(x_k)$ 的线性组合，事实上

$$f[x_0, x_1, \dots, x_k] = \sum_{j=0}^k \frac{f(x_j)}{\omega'_{k+1}(x_j)}$$

- ▶ 差商具有对称性，即差商与节点顺序无关

$$f[x_0, x_1, \dots, x_k] = f[x_1, x_0, \dots, x_k] = \dots = f[x_1, x_2, \dots, x_k, x_0]$$

Pf: (1).数学归纳法 (2). 由(1)直接得到

差商表

x_i	$f(x_i)$	一阶差商	二阶差商	k 阶差商
x_0	$f(x_0)$			
x_1	$f(x_1)$	$f[x_0, x_1]$		
x_2	$f(x_2)$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$	
x_3	$f(x_3)$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	
x_4	$f(x_4)$	$f[x_3, x_4]$	$f[x_2, x_3, x_4]$	
\vdots	\vdots	\vdots	\vdots	\vdots
x_k	$f(x_k)$	$f[x_{k-1}, x_k]$	$f[x_{k-2}, x_{k-1}, x_k]$	$\cdots f[x_0, x_1, \cdots, x_k]$

Table: 同列维尔法：每次用前一列同行的差商与前一列上行的差商再做差商

Newton 插值多项式

$$f[x, x_0] = \frac{f(x) - f(x_0)}{x - x_0} \Rightarrow f(x) = f(x_0) + f[x, x_0](x - x_0)$$

$$f[x, x_0, x_1] = \frac{f[x, x_0] - f[x_0, x_1]}{x - x_1} \Rightarrow f[x, x_0] = f[x_0, x_1] + f[x, x_0, x_1](x - x_1)$$

...

$$f[x, x_0, \dots, x_n] = \frac{f[x, x_0, \dots, x_{n-1}] - f[x_0, \dots, x_n]}{x - x_n}$$

$$\Rightarrow f[x, x_0, \dots, x_{n-1}] = f[x_0, \dots, x_n] + f[x, x_0, \dots, x_n](x - x_n)$$

所以

$$f(x) = f(x_0) + f[x_0, x_1](x - x_0) + \dots + f[x, x_0, \dots, x_n](x - x_0) \cdots (x - x_n)$$

令

$$P_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \cdots + f[x_0, \dots, x_n](x - x_0) \cdots (x - x_{n-1})$$

$$R_n(x) = f[x, x_0, \dots, x_n](x - x_0) \cdots (x - x_n)$$

则

$$f(x) = P_n(x) + R_n(x)$$

其中 $P_n(x)$ 称为 Newton 插值多项式, $R_n(x)$ 称为 Newton 插值多项式余项

Theorem 1.2.1

已知 $(x_i, y_i), i = 0, \dots, n$, 其中 $y_i = f(x_i)$, 则满足 $y_i = P(x_i)$ 的插值多项式为

$$f(x) = P_n(x) + R_n(x)$$

Theorem 1.2.2

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i)$$

Pf: 利用插值多项式的唯一性

Theorem 1.2.3

$$f[x_0, x_1, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!}$$

Example 1.2.3

已知 $y = f(x)$ 的插值点, 求 Newton 三次插值多项式 $P_3(x)$

i	0	1	2	3
x_i	0	1	2	3
y_i	1	3	9	27

差分与等距节点的Newton插值

Definition 1.3.1

$y = f(x)$ 的向前差分:

► 一阶向前差分: $\Delta f_k = f(x_{k+1}) - f(x_k)$

► 二阶向前差分:

$$\Delta^2 f_k = \Delta f_{k+1} - \Delta f_k = y_{k+2} - 2f(x_k + 1) + f(x_k)$$

► m阶向前差分: $\Delta^m f_k = \Delta^{m-1} f_{k+1} - \Delta^{m-1} f_k$

Definition 1.3.2

$y = f(x)$ 的向后差分:

► 一阶向后差分: $\nabla f_k = f(x_k) - f(x_{k-1})$

► m阶向后差分: $\nabla^m f_k = \nabla^{m-1} f_k - \nabla^{m-1} f_{k-1}$

Definition 1.3.3

$y = f(x)$ 的中心差分:

► 一阶中心差分: $\delta f_k = f(x_k + h/2) - f(x_k - h/2)$

► m阶中心差分: $\delta^m f_k = \delta^{m-1} f_{k+1/2} - \delta^{m-1} f_{k-1/2}$

Definition 1.3.4

- ▶ 不变算子: $I f(x_k) = f(x_k)$
- ▶ 位移算子: $E f(x_k) = f(x_k + h) = f(x_{k+1})$
- ▶ 微分算子: $D f(x_k) = f'(x_k)$

Theorem 1.3.1

- ▶ $E^n f(x_k) = f(x_k + nh); I^n = I$
- ▶ $\Delta = E - I, \nabla = I - E^{-1}$
- ▶ $\delta = E^{1/2} - E^{-1/2} = E^{1/2}(I - E^{-1}) = E^{1/2}\nabla$
- ▶ $f \in P_n$, 则 $\Delta^k f(x) \in P_{n-k}, k \leq n; \Delta^k f(x) = 0, k > n$
- ▶ 差分与函数函数值可互相线性表示: $\Delta^m f_k = \sum (-1)^{m-i} f_{k+i}$
- ▶ $f[x_0, x_1, \dots, x_k] = \Delta^k y_0 / (k! h^k)$

Newton 向前 (后)等距插值公式(差分)

设 $x_k = x_0 + kh$, h 为步长。

- 若 $x = x_0 + th, t \in (0, 1)$, 则 Newton 向前公式为:

$$N_n(t) = y_0 + \sum_{i=1}^n \frac{t(t-1)\cdots(t-i+1)}{i!} \Delta^i y_0$$

$$R_n(t) = \frac{f^{(n+1)}(\xi)}{(n+1)!} t(t-1)\cdots(t-n)h^{n+1}$$

- $x = x_n + th, t \in (-1, 0)$, 则 Newton 向后公式为

$$N_n(t) = y_n + \sum_{i=1}^n \frac{t(t+1)\cdots(t+i-1)}{i!} \Delta^i y_0$$

$$R_n(t) = \frac{f^{(n+1)}(\xi)}{(n+1)!} t(t+1)\cdots(t+n)h^{n+1}$$

Hermite 插值

Q: 构造 (Hermite) 插值多项式函数 $H(x)$, 要求

$$\begin{cases} H(x_i) = f(x_i) = y_i \\ H'(x_i) = f'(x_i) = m_i \end{cases}, i = 0, 1, \dots, n$$

Example 1.3.5

求一个三次多项式, 使得

$$\begin{cases} H(x_i) = f(x_i) = y_i \\ H'(x_i) = f'(x_i) = m_i \end{cases}, i = 0, 1$$

Ans:Idea: 考虑

$$H_3(x) = \alpha_0(x)y_0 + \alpha_1(x)y_1 + \beta_0(x)m_0 + \beta_1(x)m_1$$

其中 $\alpha_i, \beta_i \in P_3$

Example 1.3.6

利用如下插值条件，构造相应的多项式

$$\begin{cases} H(x_i) = f(x_i) = y_i \\ H'(x_1) = f'(x_1) = m_1 \end{cases}, i = 0, 1, 2$$

Ans: 考虑利用Newton插值公式

$$H(x) = y_0 + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) \\ + c(x)(x - x_0)(x - x_1)(x - x_2)$$

一般Hermite插值多项式

$$\begin{cases} H_{2n+1}(x_i) = f(x_i) = y_i \\ H'_{2n+1}(x_i) = f'(x_i) = m_i \end{cases}, i = 0, 1, \dots, n$$

设

$$H_{2n+1}(x) = \sum_{i=0}^n \alpha_i(x)y_i + \sum_{i=0}^n \beta_i(x)m_i$$

带入插值条件，可得

$$\alpha_i = \left(1 + 2(x_i - x) \sum_{j=0, j \neq i}^n \frac{1}{x_i - x_j} \right) l_i^2(x)$$

；

$$\beta_i = (x - x_i)l_i^2(x)m_i$$

Theorem 1.3.2

满足上述条件的 $2n + 1$ 阶 *Hermite* 插值多项式是唯一的

Theorem 1.3.3

Hermite 插值多项式的误差

$$R_{2n+1}(x) = f(x) - H_{2n+1}(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \omega_{n+1}^2(x)$$

Definition 1.3.7

重节点的差商多项式

$$f[x, x, \dots, x] = \lim_{x_i \rightarrow x, i=0, \dots, n-1} f[x_0, x_1, \dots, x_{n-1}, x] = \frac{f^{(n)}(\xi)}{n!}$$

Example 1.3.8

根据插值条件，求4次Hermite插值多项式

x	H	H'	H''
0	-1	-2	
1	0	10	40

Runge现象

在科学计算领域，龙格现象（Runge）指的是对于某些函数，使用等距节点构造高阶插值多项式时，在插值区间的边缘的误差可能很大的现象。它是由Runge在研究多项式差值的误差时发现的，这一发现表明，并不是插值多项式的阶数越高，效果就会越好。

例如

$$f(x) = \frac{1}{1 + 25x^2}, x \in [-1, 1]$$

造成Runge现象的根本原因是，被插值函数的解析区域过小。上面的龙格函数虽然在实数域上有任意阶导数，但在 $x = \pm 0.2i$ 处是不解析的，因此造成了龙格现象。

可以参考*Approximation Theory and Approximation Practice, Extended Edition(SIAM 2020)* by LNT

Runge现象的克服

- ▶ chebyshev节点
- ▶ 分段低阶插值函数（分段线性函数，分段Hermite, 分段spline函数等）

带权内积

Definition 2.0.1

若定义在 $[a, b]$ 上的函数 $\rho(x)$ 满足

- ▶ $\rho \geq 0, a \leq x \leq b$
- ▶ $\int_a^b \rho|x|^n < \infty, n = 0, 1, \dots$
- ▶ $\forall f \geq 0$, 若 $\int_a^b \rho f = 0$, 则 $f \equiv 0$

称 $\rho(x)$ 为定义在 $[a, b]$ 上的权函数

Example 2.0.2

- (1). $\rho(x) = 1, x \in [0, 1]$
- (2). $\rho(x) = e^{-x^2}, x \in (-\infty, \infty)$
- (3). $\rho(x) = 1/\sqrt{1 - x^2}, x \in (-1, 1)$

Definition 2.0.3

$f, g \in C([a, b])$, ρ 为 $[a, b]$ 上的权函数, 令

$$(f, g) = \int_a^b \rho(x)f(x)g(x)dx$$

此时 (f, g) 称为函数 f 和 g 在 $[a, b]$ 上的以权为 ρ 带权内积

注意: 内积的性质在矩阵论内积空间部分已有介绍

Theorem 2.0.1

- ▶ $(f, g) = (g, f)$
- ▶ $(\lambda f, g) = \lambda(f, g), \forall \lambda \in R$
- ▶ $(f_1 + f_2, g) = (f_1, g) + (f_2, g)$
- ▶ $(f, f) \geq 0$, 且 $(f, f) = 0$ iff $f = 0$

Definition 2.0.4

范数:

$$\|f\|^2 = (f, f) = \int_a^b \rho(x)|f(x)|^2 dx$$

Theorem 2.0.2

- ▶ $|(f, g)| \leq \|f\| \|g\|$
- ▶ $\|f + g\| \leq \|f\| + \|g\|$
- ▶ $\|f + g\|^2 + \|f - g\|^2 = 2(\|f\|^2 + \|g\|^2)$

Definition 2.0.5

$(f, g) = 0$, 则称 f 与 g 正交

Definition 2.0.6

假设函数列 $\{\phi_k\}_{k=1}^n \subset C([a, b])$, 若

$$\sum_{i=1}^n c_i \phi_i(x) = 0 \Leftrightarrow c_k = 0, k = 1, \dots, n$$

则称 $\{\phi_i\}_{i=1}^n$ 线性无关, 否则线性相关。

Definition 2.0.7

定义

$$span\{\phi_1, \phi_2, \dots, \phi_n\} := \left\{ \sum_{i=1}^n c_i \phi_i, \forall c_i \in R, 1 \leq i \leq n \right\}$$

Theorem 2.0.3

$\{\phi_k\}_{k=1}^n$ 线性当且仅当 $\det((\phi_i, \phi_j))_{1 \leq i \leq n, 1 \leq j \leq n} \neq 0$

最佳二次（平方）逼近

- ▶ 请回忆矩阵论中最佳二次逼近问题
- ▶ 设 $f \in C([a, b])$, 求出一个 n 多项式 $s_n^*(x)$, 使得

$$\|f(x) - s_n^*\| = \min_{\forall p_n \in P_n} \|f(x) - p_n(x)\|$$

- ▶ 设 $f \in C([a, b])$, 求出一个 $s_n^*(x) \in \text{span}\{\phi_1, \dots, \phi_n\}$, 使得

$$\|f(x) - s_n^*\| = \min_{\forall p_n \in \text{span}\{\phi_1, \dots, \phi_n\}} \|f(x) - p_n(x)\|$$

设 $s_n^*(x) = \sum_{i=1}^n \alpha_i \phi_i(x)$, 则

$$R_n(\alpha_1, \dots, \alpha_n) = \|f - s_n^*\|^2 = \int_a^b \rho(x) \left(f(x) - \sum_{i=1}^n \alpha_i \phi_i(x) \right)^2 dx$$

$$\Rightarrow \frac{\partial R_n}{\partial \alpha_i} = 0, 1 \leq i \leq n$$

$$\Rightarrow (f, \phi_k) = \sum_{i=1}^n \alpha_i (\phi_i, \phi_k), 1 \leq k \leq n$$

即

$$\begin{pmatrix} (\phi_1, \phi_1) & \cdots & (\phi_n, \phi_1) \\ (\phi_1, \phi_2) & \cdots & (\phi_n, \phi_2) \\ \vdots & \cdots & \cdots \\ (\phi_1, \phi_n) & \cdots & (\phi_n, \phi_n) \end{pmatrix} \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{pmatrix} = \begin{pmatrix} (f, \phi_1) \\ (f, \phi_2) \\ \vdots \\ (f, \phi_n) \end{pmatrix}$$

记为 $A\alpha = F$

Theorem 2.0.4

若 α 满足上述线性方程，则 $s_n^*(x) = \sum_{i=1}^n \alpha_i \phi_i(x)$ 为最佳二次逼近。此时误差：

$$\|f - s^*\|^2 = \|f\|^2 - (f, s^*)$$

Example 2.0.8

- ▶ 设 $\rho = 1$, $\phi_i = x^i$, $0 \leq i \leq n$, 求 f 在 $span\{\phi_0, \phi_1, \dots, \phi_n\}$ 上的最佳二次逼近。
- ▶ 设 $f(x) = \sqrt{x}$, $n = 1$

上述方法的缺点：需要求 A^{-1} ，若 A 的尺度比较大或者病态矩阵，则求拟不是一个好的选择。

正交多项式

Definition 2.0.9

g_n 为 $[a, b]$ 上的 n 阶多项式， $n = 0, 1, \dots$ ，若

$$(g_i, g_j) = \begin{cases} A_i (\neq 0), & i = j \\ 0, & i \neq j \end{cases}$$

则称 $\{g_n\}$ 为 $[a, b]$ 上的正交多项式

Theorem 2.0.5

$\{g_n, n = 0, 1, \dots\}$ 为 $[a, b]$ 上的正交多项式当且仅当对任意 $k = 1, \dots$,

$$(g_k, p_j) = 0$$

，这里 $p_j(x)$ 是 $[a, b]$ 上任意不超过 $k - 1$ 阶的多项式

Theorem 2.0.6

- ▶ $\{g_n\}$ 线性无关
- ▶ g_n 的有 n 个互异零点且属于 (a, b)
- ▶ 若 g_n 首项为一, 则

$$g_{n+1} = (x - B_n)g_n - C_n g_{n-1}$$

, 这里 $B_n = \frac{(xg_n, g_n)}{(g_n, g_n)}$; $C_n = \frac{(g_n, g_n)}{(g_{n-1}, g_{n-1})}$

Legendre多项式和Chebyshev多项式

	$[a, b]$	ρ	$P_0(x)$	$P_n(x)$
Legendre多项式	$[-1, 1]$	1	1	$\frac{n!}{(2n)!} \frac{d^n}{dx^n} (x^2 - 1)^n$
Chebyshev多项式	$[-1, 1]$	$\frac{1}{\sqrt{1 - x^2}}$	1	$\cos(n \arccos(x))$

若 $\{\phi_n\}$ 为 $[a, b]$ 上的正交多项式，则由最佳二次多项式的充要条件

$$\begin{pmatrix} (\phi_1, \phi_1) & \cdots & (\phi_n, \phi_1) \\ (\phi_1, \phi_2) & \cdots & (\phi_n, \phi_2) \\ \cdots & \cdots & \cdots \\ (\phi_1, \phi_n) & \cdots & (\phi_n, \phi_n) \end{pmatrix} \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{pmatrix} = \begin{pmatrix} (f, \phi_1) \\ (f, \phi_2) \\ \vdots \\ (f, \phi_n) \end{pmatrix}$$

$$\Rightarrow \alpha_i = \frac{(f, \phi_i)}{(\phi_i, \phi_i)}, i = 1, \dots, n$$

曲线拟合的最小二乘法

离散条件下的最佳平方逼近问题：给定数据 $(x_i, y_i), 1 \leq i \leq n$,
选取线性无关的函数组 $\{\phi_i\}_{i=1}^m$ 以及权函数 $w(x)$, 要求找到函数

$$\phi^*(x) = \sum_{i=1}^m \alpha_i \phi_i(x) \in \Phi := \text{span}\{\phi_1, \dots, \phi_m\}$$

使得

$$\begin{aligned} & \sum_{i=1}^n w(x_i) (y_i - \phi^*(x_i))^2 \\ &= \min I(\alpha_1, \dots, \alpha_m) := \min_{\forall \phi \in \Phi} \sum_{i=1}^n w(x_i) (f(x_i) - \phi(x_i))^2 \end{aligned}$$

Definition 2.0.10

设函数 $f(x), g(x)$; 已知 $(x_i, f(x_i))$ 和 $(x_i, g(x_i)), i = 1, \dots, n$, 定义 f 和 g 的带权 $w(x)$ 内积:

$$(f, g) = \sum_{i=1}^n w(x_i) f(x_i) g(x_i)$$

利用

$$I = (f - \phi, f - \phi),$$

$$\frac{\partial I}{\partial \alpha_j} = 0 \Rightarrow (f, \phi_j) = \sum_{j=1}^m \alpha_i (\phi_j, \phi_i), 1 \leq j \leq m$$

即

$$\begin{pmatrix} (\phi_1, \phi_1) & \cdots & (\phi_m, \phi_1) \\ (\phi_1, \phi_2) & \cdots & (\phi_m, \phi_2) \\ \cdots & \cdots & \cdots \\ (\phi_1, \phi_m) & \cdots & (\phi_m, \phi_m) \end{pmatrix} \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{pmatrix} = \begin{pmatrix} (f, \phi_1) \\ (f, \phi_2) \\ \vdots \\ (f, \phi_m) \end{pmatrix}$$

(与积分格式下最佳二次逼近的系数方程一样,称为正规方程)

$$\Leftrightarrow A^T W A \alpha = A^T W Y$$

这里

$$A = \begin{pmatrix} \phi_1(x_1) & \cdots & \phi_1(x_n) \\ \phi_2(x_1) & \cdots & \phi_2(x_n) \\ \cdots & \cdots & \cdots \\ \phi_m(x_1) & \cdots & \phi_m(x_n) \end{pmatrix}_{m \times n}$$

和 $\alpha = (\alpha_1, \dots, \alpha_m)^T$, $Y = (f(x_1), \dots, f(x_m))^T$, $W = (w(x_1), \dots, w(x_n))^T$

Theorem 2.0.7

$$A^T W A \alpha = A^T W Y$$

的解 α 是最佳平方逼近函数 $\phi^* \in \Phi$ 的系数, 即

$$\phi^*(x) = \sum_{i=1}^m \alpha_i \phi_i(x)$$

此时, 误差

$$R = \|f - \phi^*\|^2 = (f, f) - (f, \phi^*)$$

Example 2.0.11

多项式的最佳逼近, 即 $\phi_i(x) = x^i, 0 \leq i \leq m$.

此时

$$(\phi_i, \phi_j) = \sum_{l=1}^n w(x_l) x_l^{i+j}; \quad (f, \phi_i) = \sum_{l=1}^n w(x_l) f(x_l) x_l^i$$

注意：

$$A^T W A \alpha = A^T W Y$$

的求解可以利用矩阵论的知识 $A Y = b$ 不相容，则 $Y = A^+ b$ 是最佳二乘解。此时考虑 A 列或者行的线性无关性，化简公式

$$A^+ = C^H (C C^H)^{-1} (B^H B)^{-1} B^H$$

Example 2.0.12

exe3.4,3.5,3.6

正交多项式的最佳二次逼近

若 $\{\phi_i\}_{i=1}^m$ 是正交多项式，即

$$(\phi_i, \phi_j) = \delta_{ij} = \begin{cases} A_i, & i = j \\ 0, & i \neq j \end{cases}$$

， 则由最佳二次逼近的系数方程知

$$\alpha_i = \frac{(f, \phi_i)}{(\phi_i, \phi_i)}, i = 1, \dots, m$$

此时，最佳二次逼近函数为

$$\phi^*(x) = \sum_{i=1}^m \frac{(f, \phi_i)}{(\alpha_i, \alpha_i)} \phi_i(x)$$

误差估计：设 $f = (f(x_1), \dots, f(x_n))^T \in R^n$,
 $\phi^* = (\phi^*(x_1), \dots, \phi^*(x_n))^T \in R^n$, 则误差

$$R^2 = \|f - \phi^*\|^2 = (f - \phi^*, f)$$

正交多项式的推导

- ▶ 设 $\Phi = \{1, x, x^2, \dots, x^n, \dots\}$, 如何推导相应的正交多项式
- ▶ 利用正交多项式的递推公式

$$g_{n+1} = (x - B_n)g_n - C_n g_{n-1}$$

, 这里 $C_n = \frac{(xg_n, g_n)}{(g_{n-1}, g_{n-1})}$; $B_n = \frac{(g_n, g_n)}{(g_{n-1}, g_{n-1})}$

数值积分

数值积分问题：已知定义在 $[a, b]$ 上的函数 $f(x)$, 求 $\{x_i, A_i\}_{i=0}^n$, 其中 $a \leq x_0 < x_1 < \cdots < x_n \leq b$, $A_i \in R, 0 \leq i \leq n$ 使得

$$\int_a^b f(x)dx \approx \sum_{i=0}^n A_i f(x_i)$$

此时 $I_n(f) = \sum_{i=0}^n A_i f(x_i)$ 称为**积分公式**

思路：

- ▶ 考虑已知 $\{x_i\}$ (如取等距节点 $x_i = a + ih, h = (b - a)/2$), 令 $f(x) = x^i, 0 \leq i \leq n$ 时上式精确成立。
- ▶ 考虑插值多项式
- ▶ 考虑 $\{x_i\}$ 未知, 此时有 $(2n + 2)$ 个未知数 $\{x_i, A_i\}_{i=0}^n$, 令 $f(x) = x^i, 0 \leq i \leq 2n + 1$ 时积分公式精确成立

设积分公式 $\int_a^b f(x)dx = \sum_{i=0}^n A_i f(x_i)$ 对 $f(x) = x^i, 0 \leq i \leq n$ 成立, 即

$$\begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_0 & x_1 & \cdots & x_n \\ \cdots & \cdots & \cdots & \cdots \\ x_0^n & x_1^n & \cdots & x_n^n \end{pmatrix} \begin{pmatrix} A_0 \\ A_1 \\ \vdots \\ A_n \end{pmatrix} = \begin{pmatrix} b-a \\ \frac{1}{2}(b^2 - a^2) \\ \vdots \\ \frac{1}{n+1}(b^{n+1} - a^{n+1}) \end{pmatrix}$$

若 $\{x_i\}_{i=0}^n$ 互异, 则上式有唯一解, 并确定出积分公式

$I_n(f) = \sum_{i=0}^n A_i f(x_i)$ 对 $f(x) = x^i, 0 \leq i \leq n$ 精确成立, 此时我们称积分公式的代数精度为 n .

梯形公式和Simpson公式

- ▶ 梯形公式：令 $x_0 = a, x_1 = b$, 此时

$$I_n(f) = \frac{b-a}{2} (f(a) + f(b))$$

代数精度=2

- ▶ Simpson公式，令 $x_0 = a, x_1 = (a+b)/2, x_2 = b$, 此时

$$I_n(f) = \frac{b-a}{6} \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right)$$

代数精度=3

插值型求积公式

设 $L_n(x) = \sum_{i=0}^n l_i(x)f(x_i)$ 为 n 阶 Lagrange 插值公式，依此定义 n 阶代数精度的插值型积分公式

$$\int_a^b L_n(x) dx = \sum_{i=0}^n A_i f(x_i)$$

这里 $A_i = \int_a^b l_i(x) dx, 0 \leq i \leq n.$

此时余项

$$R_n(f) = \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x) dx$$

这里 $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i), \xi \in (a, b).$

Theorem 3.0.1

求积公式 $I_n(f) = \sum_{i=0}^n A_i f(x_i)$ 的代数精度至少为 n 的充要条件时该求积公式为插值型求积公式。

Example 3.0.1

求

$$I(f) = \int_0^3 f(x) dx$$

3阶代数精度的求积公式.

求积公式的收敛性与稳定性

Definition 3.0.2

► 若

$$\lim_{n \rightarrow \infty} I_n(f) = I(f)$$

称求积公式 $I_n(f)$ 收敛

► 若 $\tilde{f}(x_i) = f(x_i) + \delta_i, 0 \leq i \leq n$, 对 $\forall \epsilon > 0$, 当
 $\delta = \max_{0 \leq i \leq n} |\delta_i|$ 充分小时, 有 $|I_n(f) - I_n(\tilde{f})| < \epsilon$, 称积分公
式 $I_n(f)$ 是稳定的

Theorem 3.0.2

积分公式 $I_n(f) = \sum_{i=0}^n A_i f(x_i)$ 中, 若 $A_i > 0, 0 \leq i \leq n$, 则 $I_n(f)$ 稳
定.

Newton-Cotes 积分公式

令 $x_i = a + ih, 0 \leq i \leq n, h = (b - a)/n$, 此时所构造出来的插值积分公式称为Newton-Cotes 积分公式

$$I_n(f) = \sum_{i=0}^n A_i f(x_i),$$

这里

$$A_i = \frac{(-1)^{n-i}}{n \cdot i!(n-i)!} \int_0^n \prod_{j=0}^n (t - j) dt$$

缺点：不稳定 (A_i 不全为正)

Theorem 3.0.3

当 $n = 2k, k \in N$, Newton-Cotes 公式至少有 $(2k + 1)$ 阶代数精度.

Example 3.0.3

根据 f 的条件, 构造相应的积分公式并判断误差

- ▶ f 在 $[a, b]$ 有 2 阶连续导数
- ▶ $f^{(4)}$ 在 $[a, b]$ 存在且连续

Newton-Cotes 公式:

- ▶ 不稳定, 对于某些函数, 如 $f(x) = 1/(1+x)$, 积分公式不收敛
- ▶ 解决思路: 将区间 $[a, b]$ 分段, 每一段用低阶 Newton-Cotes 公式

(等距节点)复化求积公式

► 复化梯形公式:

$$I_n(f) = \frac{h}{2}(f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b))$$

$$R_n(f) = -\frac{b-a}{12} h^2 f''(\xi)$$

► 复化Simpson公式

$$I_n(f) = \frac{h}{6} \left(f(a) + 4 \sum_{i=1}^{n-1} f(x_{i+1/2}) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right)$$

$$R_n(f) = -\frac{b-a}{180} \left(\frac{h}{2}\right)^4 f^{(4)}(\xi)$$

Example 3.0.4

利用复化梯形公式与复化Simpson公式求

$$I(f) = \int_0^1 \frac{\sin x}{x} dx$$

并分析误差。

Romberg 算法

$$I_1(f) = \frac{b-a}{2}(f(a) + f(b))$$

可以证明:

$$I_{2^n}(f) = I_{2^{n-1}}(f) + \frac{b-a}{2^n} \sum_{i=1}^{2^{n-1}} f\left(a + (2i-1)\frac{b-a}{2^n}\right)$$

(Romberg 算法)

Gauss型求积公式

Definition 3.0.5

若不限定 $\{x_i\}_{i=1}^n$, 为求 $\{x_i, A_i\}_{i=0}^n$, 此时需要 $(2n + 2)$ 个方程。令

$$I(f) = \int_a^b \rho(x)f(x)dx$$

求积公式

$$I_n(f) = \sum_{i=0}^n A_i f(x_i)$$

若 $I_n(f) = I(f)$, 当 $f(x) = x^i, 0 \leq i \leq 2n + 1$, 则 $I_n(f)$ 称为**Gauss型积分公式**, $\{x_i\}_{i=0}^n$ 称为**Gauss点**, 此时积分公式的代数精度为 $(2n + 1)$ (相应 $(n + 1)$ 点的插值积分公式的代数精度仅为 n)

Theorem 3.0.4

$\{x_i\}_{i=0}^n$ 为积分公式 $I_n(f)$ 的 *Gauss* 点当且仅当

$$\int_a^b \rho(x) P(x) \omega_{n+1}(x) dx = 0$$

其中 $P(x)$ 为任意阶数不超过 n 的多项式, $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j)$

Corollary 3.0.6

$\{\phi_i\}$ 是 $[a, b]$ 上带权 ρ 的正交多项式函数列, 此时 *Gauss* 型积分公式 $I_n(f)$ 的 *Gauss* 点即为 $\phi_{n+1}(x)$ 在 $[a, b]$ 上的零点。

Gauss型求积公式的推导:

- ▶ 利用正交多项式推导出Gauss点 $\{x_i\}_{i=0}^n$
- ▶ 利用Lagrange积分公式计算 $A_i = \int_a^b l_i(x)dx$

Example 3.0.7

求

$$I(f) = \int_0^1 f(x)dx$$

的两点Gauss积分公式

常用Gauss型求积公式

- Gauss-Legendre 公式: Legendre 多项式 $([-1, 1], \rho = 1)$

$$P_0 = 1, P_1 = x, P_{n+1} = \frac{2n+1}{n+1}P_n(x) - \frac{n}{n+1}P_{n-1}(x)$$

n	节点数	x_k	A_k	代数精度
1	2	$\pm 1/\sqrt{3}$	1	3
2	3	$\pm \sqrt{3/5}$	$5/9$	5

Table: Gauss-Legendre 求积公式

Example 3.0.8

计算 $\int_1^5 f(x)dx$, 要求有5阶代数精度

- ▶ Gauss-Chebyshev 积分公式($(-1, 1), \rho = 1/\sqrt{1 - x^2}$)

$$T_0 = 1, T_1 = x, T_{n+1} = 2xT_n(x) - T_{n-1}(x)$$

Gauss 点: $x_i = \cos \frac{2i + 1}{2(n + 1)\pi}, i = 0, \dots, n$

积分系数: $A_i = \frac{\pi}{n + 1}$

Theorem 3.0.5

- 若 f 在 $[a, b]$ 上有 $(2(n+1))$ 可导, 则Gauss型求积公式的误差为

$$R(f) = \frac{f^{2(n+1)}(\eta)}{(2n+2)!} \int_a^b \rho(x) \omega_{n+1}^2(x) dx, \eta \in (a, b)$$

- Gauss型求积公式是稳定的
- 若 $f \in C([a, b])$, 则Gauss型求积公式收敛

证明: 略

Example 3.0.9

- Gauss-Legendre公式, 当 $n = 1$ 时的误差
- Gauss-Chebyshev公式, 当 $n = 1$ 时的误差

4. ODE 问题的数值求解

常微分 (ordinary differential equation) 问题:

$$\begin{cases} y(x)' = f(x, y(x)) \\ y(a) = y_0 \end{cases}, x \in [a, b]$$

通常假设 f 满足 Lipschitz 条件

$$|f(x, y_1) - f(x, y_2)| \leq L |y_1 - y_2|$$

求解的基本思想

- ▶ 微分近似
- ▶ 积分近似
- ▶ Taylor 展式

Euler Scheme

设 $x_n = a + nh$, $h = (b - a)/n$

- ▶ forward Euler (显式格式):

$$y_{n+1} = y_n + hf(x_n, y_n)$$

- ▶ backward Euler (隐式格式) :

$$y_{n+1} = y_n + hf(x_{n+1}, y_{n+1})$$

- ▶ 梯形公式:

$$y_{n+1} = y_n + \frac{h}{2}(f(x_n, y_n) + f(x_{n+1}, y_{n+1}))$$

隐式格式的实现

Algorithm for BE:

1. initial guess : $y_{n+1}^{(0)}$
2. while $|y_n^{(k+1)} - y_n^{(k)}| > \epsilon$, do 3, 4
3. $y_{n+1}^{(k+1)} = y_n + hf(x_{n+1}, y_{n+1}^{(k)})$
4. $k = k + 1$
5. $y_{n+1} = y_{n+1}^{(k+1)}$

收敛性(压缩映射定理): if $hl < 1$, then

$$|y_{n+1}^{(k+1)} - y_{n+1}^{(k)}| \leq (hl)^k |y_{n+1}^{(1)} - y_{n+1}^{(0)}| \rightarrow 0, k \rightarrow \infty$$

改进的隐格式

- 改进的向后 Euler:

$$y_{n+1}^{(0)} = y_n + hf(x_n, y_n),$$

- 改进的梯形公式:

$$\bar{y}_{n+1} = y_n + hf(x_n, y_n) \text{ (预测)}$$

$$y_{n+1} = y_n + \frac{h}{2}(f(x_n, y_n) + f(x_{n+1}, \bar{y}_{n+1})) \text{ (校正)}$$

误差与计算精度

Definition 4.0.1

- ▶ 局部误差指的是scheme中一步的误差，以Forward Euler为例：

$$\epsilon_l = y(x_{n+1}) - y(x_n) - hf(x_n, y(x_n))$$

- ▶ 全局误差指的是scheme算到最后的 y_{n+1} 时的累积误差，以Forward Euler 为例

$$\epsilon = y(x_{n+1}) - y(x_n) - hf(x_n, y_n)$$

- ▶ 若scheme $\epsilon_l = O(h^{p+1})$, 则称该scheme有 p 阶精度

Example 4.0.2

求证梯形公式的精度 $p = 2$, 向前向后Euler的精度 $p = 1$

Runge-Kutta方法

由 $y' = f(x, y)$, 知道 $f(x, y)$ 是函数 $y = y(x)$ 在 x 的切线斜率。
故 $f(x_{n+1}, y_{n+1})$ 是 $y = y(x)$ 在 $x = x_{n+1}$ 的切线斜率.但是在计算
中 y_{n+1} 不知道, 因此可以考虑

$$f(x_{n+1}, y_{n+1}) = \sum_{i=1}^m \alpha_i k_i$$

这里 $\sum_{i=1}^m \alpha_i = 1$,

$$k_1 = f(x_n, y_n), k_i = f(x_n + \lambda_i h, y_n + \lambda_i h k_{i-1}), i = 2, \dots, m$$

$\lambda_i \in [0, 1]$. 此时考虑选取合适的 $\{\alpha_i, \lambda_i\}_{i=2}^m$ 使得格式

$$y_{n+1} = y_n + \sum_{i=1}^m \alpha_i k_i$$

尽可能精确。可以证明, 这种条件下不同 m 推导的scheme的局
部精度不会超过 m 阶, 甚至小于 m

(2级)2阶R-K公式

设 $f_n = f(x_n, y_n)$

- ▶ 中点公式: $\lambda_2 = 1/2, \alpha_1 = 0, \alpha_2 = 1$

$$y_{n+1} = y_n + h[f(x_n + h/2, y_n + hf_n/2)]$$

- ▶ Heun公式: $\lambda_2 = 2/3, \alpha_1 = 1/4, \alpha_2 = 3/4$

$$y_{n+1} = y_n + \frac{h}{4}[f_n + 3f(x_n + 2h/3, y_n + 2hf_n/3)]$$

- ▶ $\lambda_2 = 1, \alpha_1 = 1/2, \alpha_2 = 1/2$

$$y_{n+1} = y_n + \frac{h}{2}[k_1 + f(x_n + h, y_n + hf_n)]$$

经典（4级）4阶Runge-Kutta公式

$$\begin{cases} y_{n+1} = y_n + \frac{h}{6} (k_1 + 2k_2 + 2k_3 + k_4) \\ k_1 = f(x_n, y_n) \\ k_2 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1) \\ k_3 = f(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_2) \\ k_4 = f(x_n + h, y_n + hk_3) \end{cases}$$

Example 4.0.3

$$y' = 1 - \frac{2xy}{1+x^2}, y(0) = 0, 0 \leq x \leq 2$$

单步法的收敛性与稳定性

Definition 4.0.4

设格式 $y_{n+1} = y_n + h\phi(x_n, y_n, h)$, $x_n = a + nh$, $h = (b - a)/n$ 若

$$\lim_{h \rightarrow 0} y_n = y(x_n)$$

称该格式收敛

Theorem 4.0.1

设单步法格式具有 p 阶精度，且

- ▶ ϕ 对于 y 满足 Lipschitz 条件

$$|\phi(x, y, h) - \phi(x, \bar{y}, h)| \leq L|y - \bar{y}|$$

- ▶ 初始值精确 $y_0 = y(a)$

则该单步法收敛，并且全局误差 $e_n = |y(x_n) - y_n| = O(h^p)$

Corollary 4.0.5

高精度格式仅需提高局部精度

Example 4.0.6

分析

- ▶ 向前Euler格式
 - ▶ 改进的Euler格式
- 的收敛性。

Corollary 4.0.7

若 $f(x, y(x)) = \phi(x, y(x), 0)$, 则单步法格式的局部精度 $p = 2$

Definition 4.0.8

显式单步法

$$y_{n+1} = y_n + h\phi(x_n, y_n; h)$$

满足条件

$$y_{n+1} = y_n + h\phi(x_n, y_n; h)$$

与ODE

$$\begin{cases} y' = f(x, y) \\ y(x_0) = y_0 \end{cases}$$

相容

Theorem 4.0.2

- ▶ 显式单步法相容 \Leftrightarrow 单步法具有 p 阶精度
- ▶ 显式单步法的增量函数 $\phi(x, y; h)$ 对 y 满足 *Lipschitz* 条件, 则
单步法相容 \Leftrightarrow 单步法收敛

稳定性

▶ 单步法

$$y_{n+1} = y_n + h\phi(x_n, y_n; h)$$

，设 y_n 为单步法的精确解， \bar{y}_n 是带着舍入误差的值，则为了使舍入误差不增长，

$$\frac{|y_{n+1} - \bar{y}_{n+1}|}{|y_n - \bar{y}_n|} \leq 1$$

Definition 4.0.9

设单步法

$$y_{n+1} = y_n + h\phi(x_n, y_n; h)$$

求

$$y' = \lambda y, (\lambda \in C, Re(\lambda) < 0)$$

得到的解，

$$y_{n+1} = E(\lambda h)y_n,$$

若 $|E(\lambda h)| < 1$ ，则称单步法**绝对稳定**

Definition 4.0.10

$$y' = \lambda y, (\lambda \in C, \operatorname{Re}(\lambda) < 0)$$

称为模型方程

Example 4.0.11

求向前Euler法和改进的梯度法的绝对收敛区域和 λ 的范围

矩阵范数

Definition 5.0.1

设矩阵 $A = [a_{ij}]_{n \times n}$, 则有下列矩阵范数的定义:

- ▶ 矩阵的行范:

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

- ▶ 矩阵的列范:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

- ▶ 矩阵的2范:

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$

- ▶ 矩阵的F范:

$$\|A\|_F = \sqrt{\sum_{i,j=1}^n a_{ij}^2}$$

线性方程组的解法:Gauss消元法

考虑线性方程组

$$Ax = b, A \in R^{n \times n}, x \in R^n, b \in R^n$$

Idea: 利用初等行变换, 使得

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

$$\Leftrightarrow \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n-1} & a_{1n} \\ 0 & a_{22}^{(1)} & \cdots & a_{2n-1}^{(1)} & a_{2n}^{(1)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & a_{nn}^{(n-1)} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2^{(1)} \\ \vdots \\ b_n^{(n-1)} \end{pmatrix}$$

- ▶ 利用上三角阵的性质，求出 $x_n \rightarrow x_{n-1} \rightarrow \cdots \rightarrow x_1$
- ▶ Gauss消元法成立的充要条件为 $a_{ii}^{(i-1)} \neq 0, 1 \leq i \leq n$
- ▶ 计算复杂度(乘除法的次数): $\frac{1}{3}n^3 + n^2 - \frac{1}{3}n$

Example 5.0.2

$$\begin{cases} 2x_1 + x_2 + x_3 = 4 \\ 3x_1 + x_2 + 2x_3 = 6 \\ x_1 + 2x_2 + 2x_3 = 5 \end{cases}$$

Example 5.0.3

$$\begin{cases} 10^{-4}x_1 + x_2 = 1 \\ x_1 + x_2 = 2 \end{cases}$$

Q: 如何使上述例子的解准确?

Ans: 主元消去法: 每一步行变换之后, 作行交换, 使得相应的主元 $a_{ii}^{(i-1)}$ 最大

LU 分解与 Cholesky 分解

Idea:

- ▶ LU 分解, $A = LU$, 其中 L 和 U 分别为下三角阵和上三角阵, 且 L 的对角线为 1
- ▶ Cholesky 分解: $A = LDL^T$, 其中 L 为单位下三角阵, D 为对角阵

误差分析

Definition 5.0.4

$\|A^{-1}\|\|A\|$ 称为 A 的**条件数**, 记为 $cond(A)$

- ▶ b 有(舍入)误差 δb , 此时方程变为

$$A(x + \delta x) = b + \delta b$$

则

$$\frac{\|\delta x\|}{\|x\|} \leq cond(A) \frac{\|\delta b\|}{\|b\|}$$

- ▶ A 有(舍入)误差 δA , 此时方程变为

$$(A + \delta A)x = b$$

则

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{cond(A)\|\delta A\|/\|A\|}{1 - cond(A)\|\delta A\|/\|A\|}$$

迭代法：Jacobi迭代

Example 5.0.5

$$\begin{cases} 10x_1 - x_2 = 7 \\ -x_1 + 4x_2 = 5 \end{cases}$$

Jacobi迭代法：

1. $A = L + D + U$, L 和 U 分别为 A 的主对角线下部和上部的元构成的矩阵, D 为对角阵, 其对角元素为 A 的主对角元
2. $x = -D^{-1}(L + U)x + D^{-1}b$
3. $x^{(k+1)} = -D^{-1}(L + U)x^{(k)} + D^{-1}b$

Gauss-Seidel迭代法

Jacobi的改进，即在利用 $x^{(k)}$ 更新
 $x^{(k+1)} = [x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_n^{(k+1)}]^T$ 时，希望利用已求出
的 $x_i^{(k+1)}$ 逐步更新

1. $A = L + D + U$
2. $Dx = b - Lx - Ux$
3. $Dx^{(k+1)} = b - Lx^{(k+1)} - Ux^{(k)}$
4. $x^{(k+1)} = (D + L)^{-1}(b - Ux^{(k)})$

迭代法的收敛分析

Theorem 5.0.1

假设迭代格式

$$x = Bx + F$$

该格式收敛当且仅当

$$\lim_{k \rightarrow \infty} B^k = 0$$

Definition 5.0.6

设矩阵 $A \in R^{n \times n}$ 的特征根为 $\{\lambda_i\}_{i=1}^n$, 则定义

$$\rho(A) := \max_{1 \leq i \leq n} \{|\lambda_i|\}$$

为 A 的谱半径。

Theorem 5.0.2

$$\lim_{k \rightarrow \infty} B^k = 0$$

当且仅当 $\rho(B) < 1$

Theorem 5.0.3

迭代格式

$$x_{k+1} = Bx_k + F$$

$x^* = Bx^* + F$, 则 $\lim_{k \rightarrow \infty} x_k = x^*$ 当且仅当 $\rho(B) < 1$

Example 5.0.7

Ex:6.14,6.15

Corollary 5.0.8

事实上:

$$\|x_k - x^*\| \approx \rho(B)^k \|x_0 - x^*\|$$

若

$$\frac{\|x_k - x^*\|}{\|x_0 - x^*\|} < \epsilon$$

则

$$k > \frac{\ln(\epsilon)}{\ln(\rho(B))}$$

- $\ln(\rho(B))$ 称为迭代速度

非线性方程（组）的数值解法：二分法

Q: 设函数 $f(x)$ 在 $[a, b]$ 上连续，求 $f(x) = 0$ 的解

Ans: 二分法

- ▶ $[a_1, b_1] \supset [a_2, b_2] \supset \cdots \supset [a_k, b_k]$
- ▶ $f(a_k)f(b_k) < 0$
- ▶ $b_k - a_k = \frac{1}{2^{k-1}}(b - a), x_k = \frac{a_k + b_k}{2}$
- ▶ $|x^* - x_k| \leq \frac{b - a}{2^k}$

缺点：收敛速度很慢

迭代格式

Idea: 求方程 $f(x) = 0$, 确定函数 ϕ 使得 $x = \phi(x)$, 此时迭代格式为 $x_{k+1} = \phi(x_k)$

Example 6.0.1

$f(x) = x^3 + 4x^2 - 10$, 求 $f(x) = 0$ 的根

- ▶ Q: 如何构造 ϕ ?
- ▶ Ans: 要求 $|\phi'(x)| < 1$, 且 $|\phi'(x)|$ 越小, 收敛越快

Theorem 6.0.1

设函数 $\phi(x)$ 满足

- ▶ $\forall x \in [a, b], a \leq \phi(x) \leq b$
- ▶ $\exists L \in [0, 1),$ 使得 $|\phi'(x)| \leq L, \forall x \in [a, b]$

则 $x = \phi(x)$ 在 (a, b) 上由唯一解 x^* , 且对任意初始值 $x_0 \in [a, b]$, 均有 $x_k \rightarrow x^*, k \rightarrow \infty$, 这里 $x^* = \phi(x^*)$

Corollary 6.0.2

上述定理中，误差

$$|x_k - x^*| \leq \frac{1}{1-L} |x_{k+1} - x_k|$$

$$|x_k - x^*| \leq \frac{L^k}{1-L} |x_1 - x_0|$$

Example 6.0.3

求 $f(x) = x^3 - x - 1 = 0$ 在 $x = 1.5$ 附近的根

Example 6.0.4

求 $f(x) = e^x - x - 2 = 0$ 的迭代格式

局部收敛性

Definition 6.0.5

若存在 $I = \{x : |x - x^*| < \delta\}$, 使得对任意的 $\forall x_0 \in I$, 迭代 $x_{k+1} = \phi(x_k)$ 收敛, 则称该格式具有 **局部收敛性**

Definition 6.0.6

设 $\lim_{k \rightarrow \infty} x_k = x^*$, 定义误差 $e_k = |x_k - x^*|$, 若

$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^p} = M \neq 0$$

称 $\{x_k\}$ 具有 **p阶收敛**

迭代法加速

- ▶ 若迭代法具有线性收敛率，即 $\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k} = M \neq 0$
- ▶

$$\frac{x^* - x_{k+2}}{x^* - x_{k+1}} \approx \frac{x^* - x_{k+1}}{x^* - x_k} \Rightarrow x_{k+1} = x_k - \frac{(x_{k+1} - x_k)^2}{x_{k+2} - 2x_{k+1} + x_k}$$

- ▶ 该收敛法比 $\{x_k\}$ 收敛速度快

Newton迭代法

Idea: 利用曲线 $y = f(x)$ 的切线与 x 轴的交点去逼近 $f(x) = 0$ 的解
(用切线代替曲线 $y = f(x)$)

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

算法要求: 初始值 x_0 要在 $f(x) = 0$ 的根附近 (利用局部收敛性)

Theorem 6.0.2

$$f(x^*) = 0$$

- ▶ f 在 x^* 附近二阶可导
- ▶ $f'(x^*) \neq 0$

则 $x_k \rightarrow x^*, k \rightarrow \infty$ 收敛率为2阶

Example 6.0.7

求方程 $xe^x - 1 = 0$ 的根

Example 6.0.8

求 $\sqrt{2}$

Newton下山法

原因： Newton法需要利用局部收敛性，即初始值 x_0 要在真解 x^* 附近。如果不是，需要利用下山法：选定 $\lambda \in (0, 1]$



$$\bar{x}_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$



$$x_{k+1} = \lambda \bar{x}_{k+1} + (1 - \lambda) x_k$$

事实上，选取合适的 λ ，可以使迭代格式收敛，二不需要担心局部收敛性

Example 6.0.9

考虑 $f(x) = x^3 - x - 1 = 0$, 利用下山Newton迭代法求解。

Newton弦截法

Idea: 利用线性Newton插值法替代 $f(x)$ 求零点

$$0 = N(x) = f(x_k) + f[x_k, x_{k-1}](x - x_k)$$

$$\Rightarrow \text{Newton弦截法: } x_{k+1} = x_k - \frac{f(x_k)}{f[x_k, x_{k-1}]}$$

优点: 无需求导 $f'(x_k)$

Theorem 6.0.3

Newton弦截法的收敛率 $\rho \geq \frac{1 + \sqrt{5}}{2} \approx 1.618$

Example 6.0.10

求方程 $xe^x - 1 = 0$ 的解

Muller 抛物线法

Idea: 利用二阶Newton插值法替代 $f(x)$ 求零点

$$N(x) = f(x_k) + f[x_k, x_{k-1}](x - x_k) + f[x_k, x_{k-1}, x_{k-2}](x - x_k)(x - x_{k-1})$$

$$\text{由 } N(x) = 0$$

$$\Rightarrow \text{Muller 抛物线法: } x_{k+1} = x_k - \frac{2f(x_k)}{\omega \pm \sqrt{\omega - 4f(x_k)f[x_k, x_{k-1}, x_{k-2}]}}$$

这里

$$\omega = f[x_k, x_{k-1}] - f[x_k, x_{k-1}, x_{k-2}](x_k - x_k)$$

可以证明Muller法的收敛阶 $p \approx 1.839$

非线性方程组的Newton解法

Q: 非线性方程组

$$\begin{cases} f_1(x_1, \dots, x_n) = 0 \\ f_2(x_1, \dots, x_n) = 0 \\ \dots \\ f_n(x_1, \dots, x_n) = 0 \end{cases}$$

简记为

$$\mathbf{F}(\mathbf{x}) = 0$$

Newton迭代法

$$\mathbf{x}_{k+1} = \mathbf{x}_k - [\mathbf{F}'(\mathbf{x}_k)]^{-1} \mathbf{F}(\mathbf{x}_k)$$

这里

$$\mathbf{F}'(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \dots & \frac{\partial f_2}{\partial x_n} \\ \dots & \dots & \dots \\ \frac{\partial f_n}{\partial x_1} & \dots & \frac{\partial f_n}{\partial x_n} \end{pmatrix}$$

是 \mathbf{F} 的 Jacobi 矩阵

Example 6.0.11

求下列非线性方程组的解 $\mathbf{x} = [x_1, x_2]^T$

$$\begin{cases} x_1 + 2x_2 - 3 = 0 \\ 2x_1^2 + x_2^2 - 5 = 0 \end{cases}$$